

大语言模型部署体验报告

1 实验环境

本实验按照要求，采用 ModelScope 平台，即魔搭平台，来获取硬件资源。根据平台的自身介绍文档，其基于阿里云提供的硬件资源提供服务。因此，按照平台的文档要求，实验中使用 ModelScope 和阿里云账号来获得免费授权。由于此前已经注册过相关账号，此处注册过程省略。

实验使用的 CPU 实例是 ModelScope 平台提供的免费 CPU 实例，根据官方信息，该 CPU 基础参数为 8 核、32GB 内存，预装了平台提供的 ModelScope Library 库，并包含一个自带基础环境的镜像。该镜像具体如下：

	版本
操作系统 (Ubuntu)	ubuntu22.04
Python	3.11
PyTorch	2.3.1

这意味着，部署模型中，最耗时的 PyTorch 环境搭建已经完成。经过实际测试，在工作区下，Python、Conda、PyTorch 确实都可以正常使用，因此，在 2 中，将不再配置相关内容，仅安装其他必需的 Python 库。

平台也提供了足够可用的自带 Notebook 便于操作，具有完善的终端命令行交互、文件资源管理以及部分文档的可视化编辑（例如 Python 的.py 文件）。


考虑所选平台的性能，以及要求文档的推荐，本实验选用如下模型进行测试：

名称	参数量	训练数据	官方声称的上下文长度（未实测）
Qwen-7B-Chat	7B	>2T	8k
ChatGLM3-6B	6B	官方未公布	8k，有长文本版但本实验未用到
Baichuan2-7B-Chat	7B	约 2.6T	4k

可见 ChatGLM3-6B 的参数量小于另外两个待测模型。上下文窗口对本实验基本无影响，可以暂且忽略。

2 部署过程

首先，实验启动实例，打开 Notebook，熟悉界面和操作：



为了便于操作，使用 Bash 脚本替代逐条输入命令，来完成环境配置。如 1 所述，预装镜像已经配置了一部分，因此主要完成剩余依赖的配置：

```
pip install "intel-extension-for-transformers==1.4.2" \  
        "neural-compressor==2.5" \  
        "transformers==4.33.3" \  
        "pydantic==1.10.13" \  
        -q
```

此外，脚本做了环境检测，并检查导入来确定安装是否确实成功。这样如果临时中断实验，硬件资源被系统自动回收，也可以便捷地运行脚本重新建立环境。完整脚本详见 Git 项目中的 setup_env.sh。

实际测试，由于最耗时的依赖都被预装了，因而该脚本运行时间在 2 分钟以内。运行基本能稳定成功，因而该脚本在指定版本的镜像下稳定可用。

考虑到实验的便捷，实验每部署一个模型，就立即进行问答测试，完成后再部署下一个模型。因此，实际过程中 2 和 3 是交叉进行的。当然，这个顺序不影响逻辑，因此把部署过程集中展示。

根据三款模型的官方文档，其部署基本都只需要一条 git clone 命令。因此，在验证了网络通畅后，执行项目的克隆，从官方链接克隆项目：

```
root@dsw-1862225-75599b879b-bgvvd:/mnt/workspace# cd /mnt/data  
root@dsw-1862225-75599b879b-bgvvd:/mnt/data# git clone https://www.modelscope.cn/qwen/Qwen-7B-Chat.git  
正克隆到 'Qwen-7B-Chat'...  
remote: Enumerating objects: 554, done.  
remote: Counting objects: 100% (56/56), done.  
remote: Compressing objects: 100% (30/30), done.  
remote: Total 554 (delta 30), reused 49 (delta 26), pack-reused 498  
接收对象中: 100% (554/554), 16.47 MiB | 28.97 MiB/s, 完成。  
处理 delta 中: 100% (295/295), 完成。  
  
过滤内容: 100% (8/8), 14.38 GiB | 151.11 MiB/s, 完成。  
root@dsw-1862225-75599b879b-bgvvd:/mnt/data#
```

```
root@dsw-1862225-75599b879b-bgvvd:/mnt/data# git clone https://www.modelscope.cn/ZhipuAI/chatglm3-6b.git
正克隆到 'chatglm3-6b'...
remote: Enumerating objects: 147, done.
remote: Counting objects: 100% (25/25), done.
remote: Compressing objects: 100% (24/24), done.
remote: Total 147 (delta 11), reused 1 (delta 0), pack-reused 122
接收对象中: 100% (147/147), 78.33 KiB | 514.00 KiB/s, 完成.
处理 delta 中: 100% (63/63), 完成.
过滤内容: 100% (15/15), 23.26 GiB | 152.81 MiB/s, 完成.
root@dsw-1862225-75599b879b-bgvvd:/mnt/data#

root@dsw-1862225-75599b879b-bgvvd:/mnt/workspace# cd /mnt/data
root@dsw-1862225-75599b879b-bgvvd:/mnt/data# git clone https://www.modelscope.cn/baichuan-inc/Baichuan2-7B-Chat.git
正克隆到 'Baichuan2-7B-Chat'...
remote: Enumerating objects: 121, done.
remote: Counting objects: 100% (21/21), done.
remote: Compressing objects: 100% (21/21), done.
remote: Total 121 (delta 6), reused 0 (delta 0), pack-reused 100
接收对象中: 100% (121/121), 472.62 KiB | 4.18 MiB/s, 完成.
处理 delta 中: 100% (51/51), 完成.
root@dsw-1862225-75599b879b-bgvvd:/mnt/data#
```

3 问答测试过程

使用 Python 脚本，用 transformers 库的工具来加载、调用部署完成的模型。使用到的脚步都手动同步保存到本机，详见 Git 项目，此处不再展示全文。

选用的对话测试问题如下（该问题也即推荐问题中的第一条）：

问题	目的
请说出以下两句话区别在哪里？ 1、冬天：能穿多少穿多少 2、夏天：能穿多少穿多少	测试模型对歧义句的辨析，进而体现语义理解能力
明明明明白白白白喜欢他，可她就是不說。 这句话里，明明和白白谁喜欢谁？	测试模型断句的能力，同样体现语义理解能力
如果今天是周一，我就去图书馆还书。 今天不是周一，所以我不去还书。 请问：这个推理正确吗？请回答“正确”或“不正确”，并简要说明理由。	测试模型在没有文字游戏干扰的前提下，对逻辑谬误的识别能力，体现推理能力
李华今年 15 岁，就读于市第一中学。他的物理老师是王敏，数学老师是张强。李华最喜欢的科目是物理，他曾获得校物理竞赛一等奖。他的好朋友小丽擅长英语，两人经常一起讨论学习问题。 请根据以上文本回答： 李华就读于哪所学校？他最喜欢的科目是什么？ 文中提到了哪些老师？分别教什么科目？ 李华的好朋友是谁？她擅长什么？ 请用一段通顺的文字或分点列出答案，不要遗漏信息。	测试模型的信息搜集整合能力

实际测试中，注意到，Qwen-7B-Chat 和 ChatGLM3-6B 比较用户友好，它们的加载已经做好了分块，在实验环境中，CPU 和内存可以承担压力；此外，脚本把裸露的提示词输入，模型也可以正确处理。

但 Baichuan2-7B-Chat 如果类似操作，会存在问题。

首先，其一次性加载内容过大，直接复用前两个模型的加载方式会导致内存耗

尽，并触发 Linux 的 OOM kill。好在 transformers 提供了 `low_cpu_mem_usage` 参数，减小一次性加载的规模，且对于 Baichuan 可用。实际测试下来，设置该参数后，加载过程中 CPU 和内存占用稳定在 50% 左右，仅略高于 Qwen，足够稳定。

此外，Baichuan 强制要求用户输入的提示词要自觉遵守固定格式，用 `<reserved_106>` 开头，`<reserved_107>` 结尾，否则，实测下来，模型不会输出任何有实际意义的内容，只会输出 `</s>` 终止符。这里也可以用 Python 脚本简单解决。

在解决上述问题后，实验中可以正常完成问答。虽然模型输出词元速度很慢，但这在 CPU 上属于正常情况，且速度尚可接受，模型能支撑到输出完成，得到实验结果。

测试结果如下:

问题 1:

模型回答:

这两句话的区别在于，它们所处的季节不同。第一句话“冬天：能穿多少穿多少”表明说话者处于冬季，需要根据天气情况决定穿着多少衣服以保暖。而第二句话“夏天：能穿多少穿多少”则表示说话者处于夏季，需要考虑避免过热或出汗过多，所以也需要根据自己的舒适度和适应性来选择穿着多少衣服。总的来说，这两句话都是在表达根据环境和自身需求调整穿着的观念，但具体的语境和目的有所不同。<endofext>

模型回答:

这两句话的区别在于，第一句是关于冬天的，而第二句是关于夏天的。虽然两句话的意思相同，都是建议穿多少衣服，但是它们针对的季节不同。

```
root@dsw-1862225-75599b879b-bgvvd:/mnt/workspace# python run_baichuan.py
/usr/local/lib/python3.11/site-packages/transformers/utils/generic.py:311: FutureWarning: `torch.utils._pytree._register_pytree_node` is deprecated. Please use `torch.utils._pytree.register_pytree_node` instead.
  torch.utils._pytree._register_pytree_node(
Xformers is not installed correctly. If you want to use memory_efficient_attention to accelerate training use the following command
  install Xformers
pip install xformers.
格式化后的输入: <reserved_106>请说出以下两句话区别在哪里？
1、冬天：能穿多少穿多少
2、夏天：能穿多少穿多少<reserved_107>
```

模型回答:

```

/usr/local/lib/python3.11/contextlib.py:105: FutureWarning: `torch.backends.cuda.sdp_kernel()` is deprecated. In the future, this context manager will be removed. Please see `torch.nn.attention.sdpa_kernel()` for the new context manager, with updated signature.
  self.gen = func(*args, **kwargs)
这两句话的区别主要在于季节和气候。在冬天，人们通常建议穿更多的衣物来保暖；而在夏天，由于气温较高，人们则建议穿较少的衣物以保持凉爽。所以，第一句“冬天：能穿多少穿多少”强调的是保暖，而第二句“夏天：能穿多少穿多少”强调的是透气和散热。</s>
root@idsw-1862225-75599b879b-bgvud:/mnt/workspace#

```

问题 2:

模型回答:

明明喜欢白白。这句话的意思是什么？这句话的意思是：明明喜欢白白，但白白没有告诉他。 2. 白白不明白，明明也是真的不明白吗？是的，这两个人都是真的不明白。这句话的意思是什么？这句话的意思是：白白不知道明明是否喜欢白白，而明明也不知道白白是否明白自己的心意。 3. 明明喜欢白白，可她就不说。这句话的意思是什么？这句话的意思是：明明非常喜欢白白，但她觉得直接表达出来不合适，所以选择了沉默。 4. 白白不明白，明明也是真的不明白吗？这句话的意思是什么？这句话的意思是：虽然明明表达了自己喜欢白白，但小白并没有理解她的意思，因此他们两个都无法确定对方是否真实想法。 5. 最后，谁也没有说出真心话。这句话的意思是什么？这句话的意思是：由于误会和不信任，最终他们都无法坦诚地表达出自己的真实想法，因此到最后谁也没有说出真心话。 <endnote>

```
root@dsw-1889735-799d488d68-jx9f5:/mnt/data/LanguageModel-LocalDeployment-Test#
```



```
root@dsw-1892560-587999cbfb-rd2gs:/mnt/data/LanguageModel-LocalDeployment-Test# python run_glm.py
正在加载模型，请稍候...
Setting eos_token is not supported, use the default one.
Setting pad_token is not supported, use the default one.
Setting unk_token is not supported, use the default one.
/usr/local/lib/python3.11/site-packages/transformers/utils/generic.py:311: FutureWarning: `torch.utils._pytree._register_pytree_node` is deprecated.
lease use `torch.utils._pytree.register_pytree_node` instead.
    torch.utils._pytree._register_pytree_node(
/usr/local/lib/python3.11/site-packages/transformers/utils/generic.py:311: FutureWarning: `torch.utils._pytree._register_pytree_node` is deprecated.
lease use `torch.utils._pytree.register_pytree_node` instead.
    torch.utils._pytree._register_pytree_node(
Loading checkpoint shards: 100%|██████████| 7/7 [00:41<00:00, 5.91s/i]

模型回答：

李华就读于市第一中学。他最喜欢的科目是物理。文中提到的老师有王敏（物理老师）和张强（数学老师）。李华的好朋友是小丽，她擅长英语。
```

```
/usr/local/lib/python3.11/site-packages/transformers/utils/generic.py:311: FutureWarning: `torch.utils._pytree._register_pytree_node` is deprecated.
lease use `torch.utils._pytree.register_pytree_node` instead.
    torch.utils._pytree._register_pytree_node(
Xformers is not installed correctly. If you want to use memory_efficient_attention to accelerate training use the following command to install Xformers
pip install xformers.
格式化后的输入：<reserved_106>李华今年15岁，就读于市第一中学。他的物理老师是王敏，数学老师是张强。李华最喜欢的科目是物理，他曾获得校物理竞赛一等奖。
他的好朋友小丽擅长英语，两人经常一起讨论学习问题。
请根据以上文本回答：
李华就读于哪所学校？他最喜欢的科目是什么？
文中提到了哪些老师？分别教什么科目？
李华的好朋友是谁？她擅长什么？
请用一段通顺的文字或分点列出答案，不要遗漏信息。<reserved_107>
```

```
模型回答：
/usr/local/lib/python3.11/contextlib.py:185: FutureWarning: `torch.backends.cuda.sdp_kernel()` is deprecated. In the future, this context manager wi
be removed. Please see `torch.nn.attention.sdpa_kernel()` for the new context manager, with updated signature.
    self.gen = func(*args, **kwargs)
李华就读于市第一中学。他最喜欢的科目是物理。文中提到了两位老师，分别是物理老师王敏和数学老师张强。李华的好朋友是小丽，她擅长英语。</s>
```

Baichuan2-7B-Chat 同样提出“保暖”和“保持凉爽”，但相较于 Qwen-7B-Chat，它在联系现实气候的基础上，明确指出了对“多少”的理解（而 Qwen 完全没有指出这一点），即冬天“能穿多少穿多少”指的是要多穿，夏天则指的是要少穿，因而其语义理解相对更好。但是，模型同样没有明确针对“歧义”进行分析。因此，其仍然不够完美。

4.2 语言连贯性

问题 4 证明各个模型都具备基本的语言连贯性，可以处理自然语言句段。

但是，Baichuan2-7B-Chat 在每次输出末尾都出现异常的重复词元，由于稳定复现，所以这几乎不可能是偶然，疑似为当前版本该模型的漏洞。其他模型的回答则无明显的语病、错别字。因此，Baichuan2-7B-Chat 在这一方面的表现最差。

4.3 语言组织能力

如果不考虑思考内容的正确性，三个模型通过文字表达意思的效果相近。但是，在输出长度上，Qwen-7B-Chat 组织起了最长的语段，Baichuan2-7B-Chat 次之，ChatGLM3-6B 最短。

在问题 1 在，Qwen-7B-Chat 的作答有明显的“总结-分述-总结”结果，虽然中间部分的分析过浅，并没有体现分述的意义，但在谋篇上更严谨。使用了“舒适度和适应性”“语境”等总结性词汇。然而，有趣的是，在问题 2 中，由于模型的理解出现严重偏差，难以得出答案，充斥大段语义重复、逻辑松散、自言自语且混乱的语句。这在许多 256B 甚至上 T 参数量的商用大模型中也时有发生，通常出现在解答困难问题中，是一种偶发但普遍的错误。学界有一些对此的研究，通常称这种现象为幻觉推理

（Hallucinated Reasoning，即生成大段模仿推理格式但不存在真正的逻辑关系的句子）或生成退化（Generation Degeneration，即出现大量相似的词句/段落，甚至是完全相同的内容无限循环）。

问题 1 中，Baichuan2-7B-Chat 的作答有一个简单的总起，尝试总结了区别的主要方面，也针对气候特征做了关键词的总结。语言组织略弱于 Qwen。

ChatGLM3-6B 语言始终比较简洁，但在问题 1 中无法充分表达具体的区别，在回答的组织上，虽然并不松散混乱，但确实最随意，因此语言组织相对更弱。

4.4 总结

综上所述：

Qwen-7B-Chat 在语言能力上平均最好，但在较难的问题 2 中出现明显的退化，且对语义的理解存在不足；

Baichuan2-7B-Chat 对问题的语义理解相对好一些，但语言能力上不如 Qwen，且存在一个稳定复现的末尾最后一字重复问题；

ChatGLM3-6B 在一系列问题下整体表现最差，但没有出现明显的硬性漏洞。

综合官方的信息，可以作如下分析：

1) ChatGLM3-6B 参数量小于另外两个测试模型，在综合语言能力上也低于两者，这体现出，目前的语言模型，尤其在小参数模型中，参数的规模依然对模型表现有明显制约。参数为 7B 的两个模型的输出效果确实比 6B 模型更好，相应地，参数更大，输出速度也更慢，内存和 CPU 资源消耗相对更大。

2) Qwen-7B-Chat 语言能力较强，但没能完全理解歧义。考虑到官方信息中其训练数据标注为“>2T”，不确定是否达到了 Baichuan2-7B-Chat 的 2.6T 规模，因此，可能是 Qwen 模型训练数据更少，或者训练数据质量略低于 Baichuan，导致其语义理解欠缺。

3) 三个模型在面对较难问题时，都出现明显错误，不能如期完成任务。相较之下，把完全相同的问题输入现行主流的大模型（如 DeepSeek V4-flash，参数量 284B，远大于测试模型）时，结果如下：

这两句话的字面构成完全一样，都是“能穿多少穿多少”，但因为语境（冬天 vs. 夏天）不同，实际含义完全相反： 冬天：“能穿多少穿多少”中的“多少”意思是尽量多。因为天冷，要保暖，能穿多厚穿多厚，能穿几件穿几件。 夏天：“能穿多少穿多少”中的“多少”意思是尽量少。因为天热，要凉快，能穿多薄穿多薄，能不穿就不穿（在得体前提下）。 简单说：同一句话，冬天是“多多益善”，夏天是“越少越好”。区别在于对“多少”的解读取决于季节带来的实际需求。
这句话中，“明明”是人名，“白白”也是人名。整句可以理解为：明明（人名）明明（确实）明白白白（人名）喜欢他（指明明自己），可她（明明）就是不说。因此，是白白喜欢明明。
不正确。 理由：原命题“如果今天是周一，我就去图书馆还书”只规定了周一必然去还书，但没有说明非周一的情况是否一定不去还书。因此，从“今天不是周一”不能必然推出“我不去还书”，可能存在其他原因导致去还书。这个推理犯了“否定前件”的逻辑错误。
根据您提供的文本内容，回答如下： 李华就读于哪所学校？ 市第一中学。 他最喜欢的科目是什么？ 物理。 文中提到了哪些老师？分别教什么科目？ 王敏老师：教物理。 张强老师：教数学。 李华的好朋友是谁？她擅长什么？ 好朋友是小丽，她擅长英语。

显然，其回答全部正确，且语言清晰切中问题的误导点，效果远高于被测试的模型。这充分说明，目前阶段，语言模型的参数量和训练集质量对模型的表现影响是非常巨大的。参数量的提升影响明显，常见的小参数模型水平依然远低于大模型。

5 项目公开链接

项目页面链接：<https://github.com/Mavscholangki/LanguageModel-LocalDeployment-Test>

克隆时使用 `git clone` <https://github.com/Mavscholangki/LanguageModel-LocalDeployment-Test.git>